

第三阶段学习讲义

手机阅读版 · 可信知识治理与企业入库

学习范围	Workspace ACL、审计、反馈、多格式入库、pipeline、目录连接器
学习方式	第一遍直接理解，第二遍模拟面试
生成日期	2026-08-18

适合手机竖屏阅读；目录与 PDF 书签可直接跳转章节。

目录

1. 一条总链路	3
2. 工作区授权与操作审计	4
3. 受控多格式入库与结构化分块	5
4. 可编排入库：为什么是线性节点而非 DAG	7
5. 反馈与知识健康	7
6. 本地目录连接器与持续同步	8
7. 证据与当前验证口径	10
8. 不能说错的事实	11

范围：工作区授权、操作审计、用户反馈、受控多格式入库、可编排入库和本地目录连接器。

项目依据：2026-08-16 至 2026-08-17 的

P1-4.1、P1-4.2、P2 与 P3 实现及验证记录。学

习目标：能从“文件进入知识库”讲到“谁能看、如何追溯、怎样持续同步”，并清楚说明当前只完成首个连接器纵切。

1. 一条总链路

用户/目录源

- > 上传真实性校验与 LoaderRegistry 路由
- > Parse -> Chunk -> Embed -> Index
- > Document/IngestJob/Manifest
- > Workspace/KB ACL 先于检索生效
- > 回答、Citation、反馈与 Knowledge Health
- > Audit Log / ConnectorSyncRun 可追溯

这不是把若干功能拼在一起：入库解决“资料怎样可靠进入”，工作区 ACL 解决“谁能在检索前接触资料”，反馈和健康解决“使用结果怎样反哺治理”，审计与同步运行记录解决“事后怎样追溯”。

2. 工作区授权与操作审计

要记住的结论

权限检查必须发生在读取 Cache、构造 Retriever 和取得 collection 名称之前；只在 UI 隐藏按钮不能阻止越权检索。

当前实现

- `Workspace`、`WorkspaceMember` 和 `KnowledgeBase` 定义知识空间，基础角色为 owner/editor/viewer；

`KnowledgeBaseMember` 与成员组可以对单个知识库覆盖 editor/viewer，owner 不进入覆盖表。

- `require_workspace_access`、`require_accessible_knowledge_base` 等 access service 在普通/流式问答、

会话创建、预览下载、健康与其他重新读取知识库的入口实时鉴权。

- 非成员或不存在的知识库返回 404 以避免泄露存在性；已是成员但角色不足返回 403。数据库复合外键、

partial unique index 和行锁补服务层校验。

- `OperationAuditLog` 记录 ACL、用户、知识库删除和健康动作的 before/after 快照及字段 diff；仅管理员可读

[/api/admin/audit-logs](#)。

取舍与边界

这是一套产品数据库和 API 层的授权闭环，不是 Milvus 原生 ACL。当前不包含 Organization 顶层、工作区 转移/删除的完整治理，也没有把 collection 名称当作权限边界。

面试表达

我把授权前置到 Retriever 创建之前，并在每次重新读取知识库时按当前成员状态重算；因此撤销后旧会话 不能继续作为凭据。前端隐藏写操作只改善体验，真正的安全性来自服务端访问服务与数据库约束。

3. 受控多格式入库与结构化分块

要记住的结论

扩展名只决定路由，不证明文件真实类型；表格和代码不能先被普通文本 splitter 打碎再尝试修复。

当前实现

- `LoaderRegistry` 顺序注册并自检必需扩展名；重复认领在启动期报错，未知扩展名显式失败，可选

Docling/Unstructured loader 惰性加载。

- 上传由 `mime_type.py` 检查 PDF/图片签名、OOXML 容器、OLE、RTF、ODT/EPUB、SVG/HTML/文本族；

扩展名仍是最终 loader 路由，MIME 仅用来拒绝伪装内容。

- Excel 以可见 Sheet 形成表格块，处理公式缓存回退和合并单元格；PPTX 按 slide 产出文本/表格块；

图片只 OCR，不宣称视觉理解。

- `TableAwareSplitter` 与 `CodeBlockSplitter` 保护原子结构。`Chunk.text` 保持展示、Citation 和 identity 语义；`Chunk.vector_text` 只给 embedding，不能写进 payload、Manifest 或引用。

面试表达

我把“可读文本”和“更适合向量检索的表格键值表达”拆开：`text` 保持用户可核对的 Markdown 表格，`vector_text` 只在 embedding 入口使用。这样提高召回时不会改变引用证据或索引身份。

4. 可编排入库：为什么是线性节点而非 DAG

`frontend/product/services/ingestion_pipeline.py` 把入库拆成 Parse、Chunk、Embed、Index 四类节点。配置先经 `validate_pipeline` 校验唯一 start、可达性、无环、唯一且末端的 Index 等不变量；运行时由 `execute_chain` 统一返回 ok/skip/fail/terminate，失败保留 `node_id`、`node_type`、`code`、`message` 与 `retryable`。

选择线性链不是能力不足，而是当前只有确定的 Parse -> Chunk -> Embed -> Index 依赖。完整 DAG 会引入 分支汇合、状态持久化、幂等边界和重放语义；在没有明确业务节点前不应提前复杂化。旧任务没有 `pipeline_steps` 时仍走默认链路，保证存量数据兼容。

5. 反馈与知识健康

每位用户对每条助手消息只有一条 `MessageFeedback`，POST 可以提交或覆盖，DELETE 取消而非物理删除。读取会话时返回当前用户的反馈状态，因此界面刷新后不会丢失。

`negative_feedback_rate` 按实际 health sample 中 distinct `message_id` 计算；超过阈值只生成 `NEGATIVE_FEEDBACK` 诊断和建议，不修改

Knowledge Health formula 1.1 的总分。这是刻意的版本契约：把新观测直接混进旧评分，会使历史快照失去可比性。

当前没有 MQ、反馈 reason/comment UI 或管理侧聚合。同步落库是当前单节点范围内更容易验证的选择，不能宣传为跨节点异步反馈平台。

6. 本地目录连接器与持续同步

身份与版本

- `external_id` 是 root 相对规范化路径，代表稳定源身份；`content_hash` 是 sha256，代表内容版本，二者

不可混用。

- (`connector_sync_id`, `external_id`) 唯一，避免两个连接器实例相互冲突；普通上传使用不同的 partial

unique 约束。

- `mtime` + `size` 只用于快速筛选，sha256 才决定是否真的需要重新入库。

调度与四条同步

LocalDirectoryConnector 处理本地目录，也可处理操作系统已经挂载为本地路径的 SMB 目录；它不实现独立 SMB 协议客户端。默认不跟随 symlink，路径以 **root.resolve()** 和 相对路径校验防逃逸。**ConnectorSync** 保存 cursor 和下一次运行时间，**SyncLease** 以数据库 CAS 获取、续租、释放；cron 使用 5 字段、Asia/Shanghai 解释并以 UTC 存储。

一次同步依次识别变更、入队、删除和权限：

- Initial / Incremental：新增或内容变化的文件创建 connector 来源的 IngestJob。
- Delete：源文件消失时走既有文档/向量清理路径。
- Permission：只新增或提升 KB 成员角色（additive-only），不自动撤权。

ConnectorSyncRun=success 只表示源扫描和任务入队成功；实际解析、embedding、索引是否完成仍以各个 IngestJob 终态为准。租约丢失时在阶段边界中止，**next_run_at** 只在成功时推进。

当前边界

已完成的是第一个连接器纵切，不是多源企业连接平台。URL/飞书等协作源、ACL 撤销同步、连接器管理前端和 分布式锁均未实现。

7. 证据与当前验证口径

主题	主要验证记录
工作区/ACL 与审计	docs/开发记录/验证记录/2026-08-16-v05-team-trust-verification.md、 2026-08-16-operation-audit-verification.md
用户反馈	docs/开发记录/验证记录/2026-08-17-message-feedback-verification.md
多格式解析、线性入库	docs/开发记录/验证记录/2026-08-17-multi-format-parsing-verification.md、 2026-08-17-ingestion-pipeline-verification.md
本地目录连接器	docs/开发记录/验证记录/2026-08-17-connector-sync-verification.md

上述记录在各阶段完成时均有全量质量门禁证据。文档刷新当天（2026-08-18）重跑 Fast Gate：静态检查通过，Python 测试为 1130 passed、11 skipped、1 failed；失败的是 `test_live_client_disconnect_cancels_query_and_releases_runtime`，单独重跑通过。因此不能把这一次完整 Fast Gate 描述为全绿；面试或发布前应重跑并报告当次结果。

8. 不能说错的事实

1. `vector_text` 是 embedding 专用的短暂字段，不是 Citation 展示文本。
2. MIME 校验用于真实性，不取代按扩展名的 loader 路由。
3. 线性 pipeline 有节点校验和失败诊断，不等价于通用 DAG 编排引擎。
4. 消息反馈目前只产生健康诊断，不改变 formula 1.1 总分。
5. 连接器的 `external_id` 是路径身份，`content_hash` 才是内容版本。
6. SyncRun 成功不等于文件已经向量化和可检索。
7. 权限同步目前 additive-only，不能称目录 ACL 已双向一致。
8. 本地目录/已挂载 SMB 是首个连接器纵切；没有 URL、飞书等协作数据源。
9. Workspace ACL 是服务端检索前的访问控制，不是 Milvus 原生 ACL。
10. 历史测试数字只能代表对应验证记录；对外声明必须使用最新可复现结果。