

DeepSearcher

# 第三阶段面试问答复习手册

手机阅读版 · 治理、入库与连接器面试表达

|      |                              |
|------|------------------------------|
| 学习范围 | ACL、审计、反馈、结构化入库、pipeline、连接器 |
| 学习方式 | 第一遍直接理解，第二遍模拟面试              |
| 生成日期 | 2026-08-18                   |

适合手机竖屏阅读；目录与 PDF 书签可直接跳转章节。

# 目录

|                                          |   |
|------------------------------------------|---|
| 1. 为什么权限必须在检索前检查?                        | 3 |
| 2. 操作审计怎样做到可追溯而不是只记一条日志?                 | 3 |
| 3. 为什么扩展名不足以决定上传文件能否解析?                  | 4 |
| 4. 表格为什么需要双文本表示?                         | 4 |
| 5. 为什么当前选择线性入库 pipeline 而非 DAG?          | 5 |
| 6. 为什么负反馈不直接扣知识健康分?                      | 5 |
| 7. 连接器为什么同时要 external_id 和 content_hash? | 6 |
| 8. 怎样避免两个 Worker 重复跑同一个定时同步?             | 6 |
| 9. “连接器同步成功”为什么不等于“资料已可检索”?              | 7 |
| 10. 当前企业能力的最大未完成项是什么?                    | 7 |

范围：可信知识治理与企业入库。先复习 第三阶段学习讲义，再用本手册练习。

## 1.

### 为什么权限必须在检索前检查？

**结论：**如果先读取缓存、Collection 或 Retriever，再鉴权，未授权证据已经进入执行路径，UI 隐藏也无法弥补。

**回答要点：**本项目在普通/流式问答、会话创建、预览下载和健康等重读知识库的入口实时执行 access service；非成员/不存在返回 404，成员但角色不足返回 403。运行中的已授权流不在中途重新鉴权。

**边界：**这是 API 与产品数据库层授权，不是 Milvus 原生 ACL，也还没有 Organization 顶层治理。

## 2. 操作审计怎样做到可追溯而不是只记一条日志？

**结论：**审计应至少包含操作者、对象、动作、结果和前后状态，并可过滤、分页、比对字段变化。

**回答要点：**OperationAuditLog 保存 before/after JSON、JSON-pointer diff、request\_id、IP 和 user agent；ACL 变更等动作经装饰器与同库事务记录，管理员通过 `/api/admin/audit-logs` 查询。

**边界：**目前覆盖的是已埋点的产品操作，不等同于所有基础设施或数据库写入都具备不可篡改审计。

### 3. 为什么扩展名不足以决定上传文件能否解析？

**结论：**扩展名可伪造，必须把路由和真实性校验分开。

**回答要点：**LoaderRegistry 按扩展名选择 loader；MIME/容器校验检查 PDF/图片签名、OOXML 等文件结构，冲突或二进制伪装文本会拒绝。重复扩展名认领会在注册期失败，避免静默覆盖。

**边界：**MIME 校验不是恶意文件扫描，也不保证业务内容安全。

### 4. 表格为什么需要双文本表示？

**结论：**用户引用需要可读且结构完整的表格，向量检索更适合键值语义；二者强行共用会牺牲一方。

**回答要点：**`Chunk.text` 保存 Markdown 表格，`Chunk.vector_text` 提供 embedding 优化文本；embedding 唯一入口优先读取 后者，payload、identity、Manifest 和 Citation 始终使用前者。

**边界：**图片目前只 OCR，不能称为表格或图像语义理解。

## 5. 为什么当前选择线性入库 pipeline 而非 DAG?

**结论：**当前节点依赖是确定链路，先把配置校验、失败语义和兼容性做牢，比无业务分支时引入 DAG 更可控。

**回答要点：**Parse/Chunk/Embed/Index 由 `validate_pipeline` 约束 start、可达、无环和唯一末端 Index；执行结果含节点定位和 retryable，旧 job 没配置时回落默认链路。

**边界：**没有分支、聚合、持久化重放或完整 DAG 调度器。

## 6. 为什么负反馈不直接扣知识健康分?

**结论：**评分公式是版本化契约，新观测直接混分会破坏旧快照比较。

**回答要点：**反馈按 `(user_id, message_id)` 幂等落库，`negative_feedback_rate` 用 health sample 中 distinct message 计算；超过阈值产生诊断和建议，但 formula 1.1 分数不变。

**边界：**当前没有 MQ、反馈原因/备注界面和运营大盘。

## 7. 连接器为什么同时要 external\_id 和 content\_hash?

**结论：**路径身份用于定位同一源对象，内容哈希用于判断版本；把两者混在一起会误判重命名、更新和幂等。

**回答要点：**external\_id 是 root 相对规范化路径，content\_hash 为 sha256；mtime/size 只筛候选，最终由 hash 决定是否需要入队，并以 (connector\_sync\_id, external\_id) 隔离不同连接器实例。

**边界：**当前只支持本地目录，以及操作系统已挂载为本地路径的 SMB 目录；不提供独立 SMB 协议客户端，也不支持 URL 或协作数据源。

## 8. 怎样避免两个 Worker 重复跑同一个定时同步?

**结论：**用带过期时间的租约 CAS 认领、续租和释放，并且只在成功后推进调度时间。

**回答要点：**SyncLease 让 owner 才能续租/释放；租约丢失在阶段边界中止；SyncRun 分开记录扫描状态，next\_run\_at 不会在开始时提前推进。

**边界：**这是数据库租约，未使用 Redis/Redisson 一类分布式锁；文件级 sha256 幂等也仍是必要防线。

## 9. “连接器同步成功”为什么不等于“资料已可检索”？

**结论：**同步负责发现和入队，解析/embedding/index 是独立的异步任务链路。

**回答要点：**SyncRun 记录 added/updated/deleted/skipped/enqueue\_failed；真正可检索要看对应 IngestJob 的终态和 Manifest。

**边界：**把这两个状态混在一起会导致运维界面错误地把排队或失败文件报告为已同步可用。

## 10. 当前企业能力的最大未完成项是什么？

**结论：**P4 运营大盘、第二个协作数据源、ACL 撤销同步、分布式流量治理与生产级 SLO 都还未完成。

**回答要点：**当前已完成 P1-4.2、P2 和本地目录 P3 纵切；可展示验证记录，但只能称“首个连接器纵切”，不能称“企业多源同步平台”或“生产级高可用系统”。