

第二阶段面试问答复习手册

手机版 · 结论、深入回答与诚实边界

复习范围	后端接口、前端状态、RAG 评测、性能、安全与系统设计
使用方式	先独立回答，再核对结论、证据、取舍和边界
生成日期	2026-08-03

适合手机竖屏阅读；目录与 PDF 书签可直接跳转章节。

目录

一、FastAPI 与后端数据流高频题	3
二、FastAPI 面试前十分钟速记	6
三、本地代理、前端与 Trace 高频题	7
四、RAG 评测、性能与检索高频题	9
五、并发、安全与生产系统设计高频题	12
六、项目表达与质疑型追问	16
七、第二阶段面试前十分钟速记	18

范围：AI 全栈后端、可观测性、前端数据流、评测、并发、安全与系统设计。当前进度：第二阶段已完成；本册覆盖后端、全栈 Trace、评测、性能、安全和系统设计。原则：只记录真实高频主问题和合理追问，不把规划中的生产能力说成已经实现。配套材料：第二阶段学习讲义·项目问题与优化清单

一、FastAPI 与后端数据流高频题

1. 一次查询请求如何从 FastAPI 进入 DeepSearcher?

标准回答：

`POST /query` 先从 JSON Body 解析并校验 `original_query`、`max_iter`、`include_trace` 和可选 Collection。服务令牌验证后，`RuntimeRegistry` 按租户发放不可变 runtime 租约，入口调用 `online_query.query()` 或 `query_with_trace()`，并显式传入租约内的 `RAGRouter`。`RAGRouter` 再选择 `DeepSearch` 或 `ChainOfRAG`，完成 Collection 路由、Embedding、Milvus 检索和答案生成。问题不进入 URL，入口最终只返回答案、Token 和可选安全 Trace。

2. FastAPI 的 `def` 和 `async def` 有什么区别？当前项目属于哪一种？

标准回答：

同步 `def` 路由通常由 FastAPI 在线程池执行，不会直接占住事件循环；`async def` 在事件循环上执行，适合真正异步 I/O。当前入库和同步查询底层 LLM、Embedding、Milvus SDK 仍是同步调用；SSE 路由用 `asyncio.to_thread()` 承载查询并在事件循环发送阶段、检测断连。每个长调用仍会占用线程，必须配合准入限制、超时预算和并发上限，不能只改函数签名。

3. `/load-files/`

为什么不能直接理解为浏览器文件上传？

标准回答：

它接收的是 JSON 中的后端文件系统路径，随后由服务进程读取该路径。远程浏览器本机路径对服务器不可见，接口也没有接收 multipart 文件字节。因此产品工作台在外层提供 multipart 接口，持久化文件和任务状态后，再把服务端路径交给该入口；旧 `/console` 才使用临时目录兼容。生产中的大文件仍更适合对象存储直传加异步 Worker。

4. 当前配置切换为什么不适合并发和多 worker?

标准回答:

当前实现不再逐个替换 globals。Provider patch 写入共享 SQLite 控制面，发布用 expected version 做 CAS；每个 worker 在请求边界读取活动绑定并缓存不可变 runtime。旧请求持有旧租约继续完成，最后一个租约释放后才关闭旧客户端；失败候选不会替换活动版本，管理接口还支持原子回滚。

5. 为什么不能把所有业务异常都返回 500?

标准回答:

500 只表示未预期内部错误。当前参数、未授权、资源不存在、冲突、限流、依赖不可用和超时分别映射到 400/401/404/409/422/429/503/504/500；客户端只看到稳定 `code`、安全 `message`、`request_id` 和 `retryable`。未知异常日志只记录请求 ID、方法、路由模板和异常类型，不记录可能含密钥或路径的原始异常文本。

6. 当前 FastAPI

测试覆盖到了什么，没覆盖什么？

标准回答：

当前测试经过真实 TestClient lifespan，覆盖 POST 查询、SSE 顺序与取消、请求 ID、

400/401/404/409/422/429/503/504/500、CORS、租户/Collection 隔离、配置发布/回滚，以及响应和日志泄漏扫描。另有真实 Uvicorn 断连测试与 Milvus/模型/浏览器闭环。

诚实边界：732 项通过的 Python 测试和 30 项前端测试不能证明生产容量、供应商 SLA 或回答质量；仍需压测、故障注入和业务黄金集。

二、FastAPI 面试前十分钟速记

1. 同步 `def` 路由在线程池运行，但不代表端到端异步或无限并发。
2. `/load-files/` 接收后端路径，不是浏览器文件字节。
3. 配置通过共享控制面版本化发布，多 worker 在请求边界同步，旧租约延迟回收。
4. 参数校验错误可由框架返回 422，业务故障不应全部包装成 500。

三、本地代理、前端与 Trace 高频题

7. 为什么浏览器和 DeepSearcher 之间需要本地代理？

结论：代理把浏览器文件与同源 HTTP 请求转换成 DeepSearcher 当前能理解的后端路径和接口格式，同时统一超时与错误。

深入回答：浏览器不能把本机路径交给另一个服务读取。当前产品工作台使用 multipart 把 PDF 发给知识库文档接口，服务端持久化文件和任务状态后返回 202，再将服务端路径交给 `/load-files/`。保留在 `/console` 的旧学习控制台仍使用 Base64、临时目录和 `/api/ingest` 适配。查询侧也由产品会话接口与旧 `/api/query` 分别服务两套界面。

诚实边界：multipart 已解决 Base64 放大，但当前产品上传仍依赖 Web 进程本地文件和 BackgroundTasks。生产环境更适合对象存储直传加持持久化 Worker；代理也不是鉴权和校验的最终安全边界。

8. Trace 为什么不是模型思维链？

结论：Trace 是程序显式记录的路由、检索和 Token 等应用事件，没有读取模型隐藏推理。

深入回答：`TraceCollector` 只接收代码已经获得的 Agent 名称、子问题、Collection、检索结果、中间答案、支持文档、反思布尔值和 Token。它限制文档数量与长度，清理路径和 URL 参数，并对白名单 metadata 序列化。产品问答把允许公开的 Trace v2 统计事件经 SSE 增量发送；旧 `/console` 仍使用查询完成后的 JSON Trace。

诚实边界：NaiveRAG、ChainOfRAG 和 DeepSearch 已接入安全阶段事件，但公开事件是应用级统计，不包含模型隐藏推理；断线重放和 Exactly Once 仍未实现。

9. 当前产品工作台怎样管理 React 状态？旧控制台还有什么风险？

结论：产品工作台使用 TanStack Query 管理服务端状态和 Mutation，用 Fetch ReadableStream 消费问答 SSE；旧控制台仍使用本地 `useState` 并等待一次性 JSON。

深入回答：产品工作台按知识库、文档、会话设置 Query Key，Mutation 成功后使相关缓存失效并重新读取服务端；文档处理期间每两秒轮询，按钮通过 `isPending` 防止同一表单重复提交。旧 `/console` 的 `api.js` 和多个 `setState` 仍可能在并发请求下出现旧响应覆盖新响应。流式化后仍需事件状态机、`run_id`、取消和幂等归并。

诚实边界：现有组件测试和定向真实浏览器验证已保护对话恢复、SSE 停止、引用抽屉状态/焦点、响应式回流、表格语义和颜色/目标尺寸抽样；它们仍不证明所有网络竞态、屏幕阅读器矩阵或完整无障碍合规。

四、RAG

评测、性能与检索高频题

10. 你会怎样评估一个 RAG 系统？

结论：分检索、生成和系统三层评估，不能用一个总分掩盖失败位置。

深入回答：检索层看 Recall@K、MRR、nDCG、重复率和空结果率；生成层看答案正确性、Faithfulness、引用正确性和拒答准确率；系统层看 p50/p95/p99、Token、成本、失败率。黄金集需要问题、标准答案、可回答标记和金标文档或 Chunk，并绑定语料、Chunk、Embedding、模型和 Prompt 版本。

诚实边界：仓库已有 2WikiMultiHopQA 标题级 Recall 评测，但没有当前业务语料的完整答案与忠实性基线。

11. 召回好但回答差，和召回差但答案像真的，怎样区分？

结论：先检查金标证据是否进入最终 TopK，再评价答案和证据关系。

深入回答：金标进入 TopK 但答案错，主要检查生成模型、Prompt、上下文组织和冲突处理；金标未进入但答案正确，模型可能依赖参数记忆，不能视为可靠 RAG 成功；未召回且模型拒答，检索失败但安全策略正常。

诚实边界：答案语义相似不等于事实正确，LLM Judge 也有偏差和非确定性，需要规则指标与人工抽查。

12. 为什么平均延迟不足以描述用户体验？

结论：平均值会被大量快请求稀释，无法描述外部模型和多轮 Agent 造成的长尾。

深入回答：应同时报告 p50、p95、p99、超时率和成功率，并把路由、Embedding、Milvus、每轮生成和最终回答拆成 Span。180 秒是超时边界，不是 SLO。质量、延迟、Token 和失败率要共同寻找 Pareto 折中。

诚实边界：当前只在代理层记录总体 `latency_ms`，没有阶段耗时和正式 SLO。

13. 当前 Token

统计能否直接计算精确成本？

结论：不能，它主要是各次 LLM `total_tokens` 的手工累计。

深入回答：当前包含 Agent 路由、子问题、中间回答、支持文档筛选和最终答案等 LLM 调用，但没有统一拆分 input/output/cached/reasoning Token，也没有统计 Embedding 使用量。精确成本还要结合模型分项单价、失败重试、Milvus 和基础设施成本。

诚实边界：不同 Provider 的 usage 语义可能不同，现有总 Token 更适合趋势比较，不应伪装成精确账单。

14. 为什么要混合 Dense 与 BM25？RRF 有什么作用？

结论：Dense 擅长语义，BM25 擅长错误码和专有名词等字面匹配；RRF 用排名融合，避免直接比较不兼容的原始分数。

深入回答：L2 越小越近，而 BM25 通常越大越相关，范围和量纲也不同。RRF 用 $\sum 1/(k+rank)$ 合并两路名次。Milvus 代码已经有 Analyzer、BM25 Function、稀疏倒排索引和 `RRFRanker()`。

诚实边界：当前配置仍是 Dense-only，已有 Collection 也需要重建 Schema 和重新入库才能启用 Hybrid；没有当前中文语料的收益报告。

五、并发、安全与生产系统设计高频题

15. 流量扩大十倍时为什么不能只增加 Uvicorn worker?

结论：Worker 只能增加进程级处理能力，不能提高 LLM RPM/TPM、Milvus 容量或保证全局配置一致。

深入回答：一个 ChainOfRAG 请求可能放大成约十次 LLM 调用。多 worker 会复制客户端和连接；配置现在通过共享控制面同步，但每进程限流仍不是全局配额。正确顺序是入口鉴权限流、有界并发和背压、入库任务队列、依赖预算与熔断、租户隔离，最后再水平扩容。

诚实边界：当前没有正式并发压测数据，不能声称十倍流量下的吞吐或 p95。

16. 全局单例为什么不一定错误，当前真正的问题是什么？

结论：只读、无请求状态并支持并发的客户端可以共享；风险在非原子热更新、生命周期和多进程一致性。

深入回答：Trace 和 Agent 中间状态是请求局部变量，共享的只读客户端可以复用连接。当前 `RuntimeRegistry` 把 LLM、Embedding、VectorDB 和 Agent 作为一个不可变版本发布，失败候选不生效；多 worker 从共享 SQLite 读取活动绑定，旧实例按请求租约延迟回收。

诚实边界：已有原子 runtime 版本和旧实例回收协议，但仍没有对真实 OpenAI-compatible 与 Milvus 客户端做长时间高并发安全验证。

17. 当前最严重的安全边界有哪些？

结论：核心已有服务令牌、管理令牌、租户/Collection ACL、参数上限和每进程限流；剩余高优先级风险是最终用户 RBAC、URL 抓取 SSRF、上传恶意文件、分布式配额与可靠任务队列。

深入回答：`/load-files/`、Provider 切换、Manifest、重建和删除都必须携带服务令牌；租户只能访问服务端白名单 Collection，核心同样限制 `max_iter ≤ 10`，配置不回显密钥，查询改为 POST Body。仍需限制 URL 抓取目标、扫描上传内容、

把单机限流升级为共享配额，并给最终用户建立身份和角色。

诚实边界：CORS 不是鉴权，Prompt 中写“不要泄露”也不能代替服务端文档授权。

18. 当前 Trace 怎样通过 SSE 安全流式展示？

结论：Collector 已是事件发布者，核心、BFF 和前端逐事件传递白名单阶段；浏览器断开会协作取消，阶段不落库且明确不是模型思维链。

深入回答：产品 BFF 以 `POST /messages/stream` 连接核心 `POST /query/stream`，事件含版本、请求 ID、递增序号和 routing/retrieval/support/reflection 等显式执行事实。BFF 再按字段白名单重建，完成时只保存回答与可核对引用；AbortController 断开上游，核心在阶段边界检查取消并最终释放租约。

诚实边界：当前是短暂连接，没有 Query Run 持久化、Last-Event-ID 重放或 Idempotency-Key；断线后只能重新提问。

19. SSE、WebSocket 和轮询为什么此处优先 SSE？

结论：当前主要是服务端单向推送 Agent 进度，SSE 基于 HTTP、协议简单且支持事件 ID；取消可以走独立 HTTP。

深入回答：WebSocket 更适合持续双向控制、实时协作和语音；轮询最兼容但有额外请求和进度延迟。原生 EventSource 不方便携带 POST Body 和 Bearer Header，因此可用“两步式 Run API + 同源 Cookie”，或使用 Fetch Stream。

诚实边界：SSE 长连接仍需要心跳、禁用代理缓冲、慢消费者控制、连接上限和权限校验。

20. FastAPI BackgroundTasks 是否已经解决可靠入库？

结论：没有，它改善了请求体验，但不是持久化分布式任务队列。

深入回答：当前产品 API 可以先保存 Document/IngestJob 状态并返回 202，再在 Web 进程执行 `process_document`。进程崩溃、部署重启或多副本场景下，没有任务租约、自动恢复、死信和统一 Worker 调度。生产应使用持久队列、幂等任务、重试预算和卡死任务回收。

诚实边界：当前已经有 `queued/processing/succeeded/failed` 状态基础，但不能描述为生产级异步任务平台。

六、项目表达与质疑型追问

21. 请用一分钟介绍项目

标准回答：

DeepSearcher 是一个把私有文档向量化后进行多策略 RAG 问答的项目。离线侧由 PDFLoader 按页解析，按 1500/100 默认参数切成 Chunk，用千问 `text-embedding-v4` 生成 1024 维向量并写入 Docker Milvus；在线侧先由 RAGRouter 在 DeepSearch 与 ChainOfRAG 中选择，再进行 Collection 路由、迭代检索和 `qwen-plus` 最终回答。产品工作台支持独立知识库、PDF 状态、持久化对话、可核对引用和可停止 SSE；核心已有服务令牌、租户/Collection ACL、POST 查询、稳定错误码、请求 ID 和每进程限流。本次产品化优化已阶段性完成，但它仍缺少正式业务黄金集、最终用户 RBAC、分布式限流和可靠任务队列，所以我把它定位为已验证的 AI 全栈学习项目，而不是成熟生产平台。

22. 你怎样证明项目真的跑过，而不是只读了源码？

结论：展示可复现命令、真实测试输出、一次端到端演示和明确的失败记录，不使用无法复现的数字。

当前证据：2026-08-02, Python 全量 `732 passed, 10 skipped`；前端 4 个测试文件、30 项

测试、TypeScript 类型检查和 587 模块生产构建通过。真实 Milvus/模型查询按 SSE 阶段完成，浏览器验证进度、停止、引用、删除闭环、响应式与键盘基础契约。

诚实边界：这些结果证明已覆盖场景中的真实 Milvus/模型集成，但不证明供应商长期可用性、生产容量、回答质量 SLO 或完整业务黄金集表现。

23. 这个项目是不是包装上游项目？你的贡献是什么？

结论：先明确上游已有 RAG、Agent 和 Provider 抽象，再说明自己实际完成并能展示的全栈、可观测性和产品化改造。

深入回答：不能把 DeepSearch、ChainOfRAG 或 Milvus Provider 全部说成个人原创。当前可展示的改造集中在本地运行基线、runtime 版本化与租约回收、安全 SSE Trace、产品工作台、知识库与会话持久化、文档状态与引用、删除闭环、POST/错误/鉴权限流协议及前后端契约测试。每项贡献都应给出源码、测试或演示证据。

诚实边界：如果某项只是路线图或当前工作区尚未稳定完成，就使用“正在实现/下一步”，不写成已上线成果。

24. 为什么不能说完整复现了 CoRAG、实现了高并发生产平台或准确率提升？

结论：这三种说法都缺少必要证据。

深入回答：当前 ChainOfRAG 只受 CoRAG 逐步检索思想启发，没有论文训练、拒绝采样等完整流程；项目虽有服务鉴权和单机限流，但没有最终用户 RBAC、分布式配额、正式 SLO 和压测，不能称高并发生产平台；仓库虽有公开数据集 Recall 脚本，但没有当前业务黄金集和改造前后报告，不能声称准确率提升百分比。

诚实边界：准确表达边界不会减分，反而说明能够区分实现、验证和规划。

七、第二阶段面试前十分钟速记

1. 回答顺序：结论 → 因果链 → 源码/测试证据 → 取舍 → 诚实边界。
2. Trace 是应用事件，不是思维链；产品问答用 SSE 增量返回安全阶段，旧控制台仍一次性返回 JSON Trace。
3. 评测必须分检索、生成和系统三层。
4. p95/p99 比平均值更能描述长尾；超时不是 SLO。
5. Dense 找语义，BM25 找字面，RRF 按排名融合；当前未开启 Hybrid。

6. Token 总数不等于精确成本，当前也不含完整 Embedding usage。
7. `async` 关键字不能自动消除同步阻塞。
8. 全局共享客户端可以合理，但全局热更新和多 worker 一致性是风险。
9. 代理校验不是最终安全边界，Collection 名称也不是权限凭证。
10. BackgroundTasks 不是持久任务队列。
11. SSE 不保证 Exactly Once，断线也不等于取消。
12. 当前真实测试口径是 Python 全量 732 passed、10 skipped，前端 30 项测试、类型检查和 587 模块构建通过；这不等于容量、质量 SLO 或完整无障碍合规。